



Sistemas Distribuidos I (75.74)

Práctica de Arquitecturas Paralelas *Multicomputing*

Parte 1: Web Crawler.

Docentes

- Pablo D. Roca
- Guido Albarello

- Gabriel Robles
- Franco Barreneche

- Tomás Nocetti
- Nicolás Zulaica

Agenda



● *Web Crawler*



Web Crawler | Requerimientos Funcionales

- Dada una URL, obtener el HTML y analizarlo.
- Detectar nuevas URLs e identificar archivos multimedia, documentos y otras páginas Web.
- Descargar los archivos multimedia (.jpg, .png, .mp3, .ogg, etc)
- Descargar los documentos (.pdf, .odt, etc)
- Agendar el procesamiento de las nuevas páginas Web encontradas
- Detener el análisis de nuevos links luego de N anidaciones.



Web Crawler | Requerimientos No Funcionales

- Las descargas y el análisis se deben ejecutar en paralelo.
- Realizar un monitoreo constante en un archivo de texto con cantidades de:
 - URLs analizadas
 - Archivos descargados por extensión
 - Procesos en cada uno de los siguientes estados:
 - Obteniendo HTML
 - Procesando HTML
 - Descargando recurso



Web Crawler | Requerimientos (*concat*)

- Dada una URL, obtener el HTML y analizarlo.
- Detectar nuevas URLs e identificar archivos multimedia, documentos y otras páginas Web.
- Descargar los archivos multimedia (.jpg, .png, .mp3, .ogg, etc)
- Descargar los documentos (.pdf, .odt, etc)
- Agendar el procesamiento de las nuevas páginas Web encontradas
- Detener el análisis de nuevos links luego de N anidaciones.
- Las descargas y el análisis se deben ejecutar en paralelo.
- Realizar un monitoreo constante en un archivo de texto con cantidades de:
 - URLs analizadas
 - Archivos descargados por extensión
 - Procesos en cada uno de los siguientes estados:
 - Obteniendo HTML
 - Procesando HTML
 - Descargando recurso